TenseLab

Product & Domain Architecture Decision Record

Версия 0.1 • 14 октября 2026 • Статус: концепция / для продолжения разработки

Назначение документа: сохранить договорённости о продукте, контентной модели, международной локализации, типах тренировок и расширении на минимальные пары. Ниже явно отделены принятые решения, рекомендации и открытые вопросы.

1. Product vision и границы MVP

TenseLab — система целевой практики английского с фокусом на автоматизации речевых конструкций и измеримом освоении навыков, а не просто генераторе грамматически возможных предложений. Начальная аудитория: учащиеся A2–B1, понимающие правила, но медленно использующие их в речи; далее возможно расширение A1–B2 и на другие языки.

- В центре пользовательского опыта — короткое ежедневное занятие и ясное следующее действие; глубокие фильтры доступны отдельно (progressive disclosure).
- Качество примеров, естественность, смысловая корректность переводов и перенос навыка важнее количества генерируемых комбинаций.
- Продуктовую гипотезу нужно валидировать на реальных учениках; прогресс подтверждать на новых контрольных предложениях, не только на заученных карточках.

2. Структура интерфейса и учебных режимов

Раздел	Задача	Статус
Table Drills	Таблица Петрова и расширения: последовательные/случайные преобразования по временам, лицам, формам	Принято: отдельная вкладка
Translation Drills	Перевод предложений, затем при необходимости словарные задания; введённый ответ или устно	Принято: отдельная вкладка
Pattern Drills	Устойчивые и продуктивные конструкции; слоты, лица, времена, отрицания/вопросы, ситуации	Принято: отдельная вкладка
Progress / Review	Ошибки, освоение навыков, целевые повторения, аналитика	Рекомендуется
Minimal Pairs	Различение и произношение фонемных контрастов	Предлагаемое расширение

Таблицы времён можно использовать и как справочник; отдельные режимы должны переиспользовать общие модели учебных целей и упражнений, но не обязаны делить один генератор.

3. Система контента: собрать каталог прежде приоритизации

- Не вводить искусственный предел 50, 250 или 650 паттернов. Использовать Oxford Phrase List (в материалах фигурируют 650 и 750 записей) как ориентир охвата, а не как свободно распространяемый датасет.
- Сначала — каталог кандидатов; затем дедупликация и классификация, отбор приоритетов и создание примеров. Список Oxford не тождественен списку грамматических паттернов: включает коллокации, фразовые глаголы, выражения и др.
- Для каждого выбранного паттерна целевой диапазон 20–50 разнообразных, проверенных высказываний; диапазон гибкий, исходя из продуктивности конструкции.
- Фразы должны покрывать разные лица, формы, смыслы и контексты; при необходимости содержать явные ограничения применимости преобразований.
- Примеры из публичных источников требуют проверки прав; для распространения предпочтительны оригинальные/надлежащим образом лицензированные примеры. Источник, авторские права и версия фиксируются метаданными.
- Собирать частотные кандидаты из учебных и корпусных источников, но не выдавать экспертный порядок за измеренный частотный рейтинг.

Предлагаемые классы контента

Lexeme; Construction (грамматическая/валентностная модель); Expression (устойчивое выражение); PhrasalVerb как специализированная разновидность лексико-конструкционного материала; Collocation; Idiom. Не требуется жёсткое взаимоисключающее деление: у записи могут быть тип и набор категорий.

4. Архитектурное решение: first-class citizens

Вывод обсуждения: нет единого универсального корня для всего приложения. Content Catalog и Learning Engine — разные bounded contexts.

Сущность	Роль / границы
LearningItem	Общая идентичность учебного материала: тип, целевой язык, метаданные. Не giant aggregate.
Lexeme / Construction / Expression	Типизированная предметная семантика. Значения и конструкции нужно отличать от поверхностных словоформ.
LearningObjective	Центр учебного процесса: конкретный измеримый навык (понимать, распознавать на слух, производить вопрос и т. п.).
Utterance	Высказывание/реплика, не только грамматическое предложение; содержит контекст, может иллюстрировать множество LearningItems.

Exercise	Задание с целью, модальностью ответа, материалом и EvaluationPolicy; может генерироваться динамически.
Attempt / LearningProgress	Ответ и траектория освоения пользователем в разрезе LearningObjective.

Отношения: LearningItem ↔️ Utterance — many-to-many; Exercise → one/many LearningObjective; Attempt → Exercise; Progress агрегируется по objective, а не только по паттерну. Пример: «She looks like her mother» иллюстрирует look like, Present Simple (3rd person), her и может использоваться в listening.

Пример учебных целей

en.look-like.resemblance → understand.meaning; produce.present.affirmative; produce.present.negative; produce.present.question; produce.past; recognize.in.speech.

5. Минимальные пары: расширение фонологического домена

Минимальная пара — две произносительные формы, различающиеся ровно одной фонемой в заданной фонологической системе/разновидности языка, при сопоставимой структуре. Пример для контраста /ɪ/–/iː/: ship /ʃɪp/ ↔️ sheep /ʃiːp/.

Это не «лексема = звук». Фонема — фонологическая единица; Lexeme — лексическая единица со значением; Pronunciation — конкретная произносительная реализация лексической записи в акценте/варианте; MinimalPair — отношение двух Pronunciations, служащее материалом для упражнений.

Сущность	Назначение
Phoneme	Фонологическая категория, IPA-символ, язык/фонологическая система; не отдельное слово.
Pronunciation	Транскрипция, последовательность фонем, variety/accent, возможно аудио; связана с Lexeme/Expression.
PhonemeContrast	Пара различаемых фонем в пределах определённого варианта языка, например /ɪ/ vs /iː/.
MinimalPair	Отношение двух Pronunciation ID; ссылка на контраст, проверенный метод установления и источник.
AudioAsset	Запись диктора/TTS, происхождение, лицензия, акцент, качество.
LearningObjective	discriminate.phonemes, identify.spoken.word, produce.phoneme, pronounce.word; измеримый навык.

Тонкости реализации минимальных пар

- Сопоставлять фонемные последовательности, а не написания; графемная похожесть не обязательна.
- Хранить акцент/вариант языка; пары могут быть минимальными в одном акценте и не быть такими в другом.
- Разделить perception и production: распознавание аудио и собственное произношение требуют разных способов оценивания.
- Для упражнений на звуки удобно также иметь near-minimal pairs, но явно маркировать их отдельно; не записывать как строгую MinimalPair.
- Не полагаться только на TTS при проверке тонких контрастов: желательно аудио с контролем качества и произношения.

Пример JSON (псевдосхема)

```
{
 "id": "mp.en.gb.ship-sheep",
 "type": "minimal_pair",
 "language": "en",
 "variety": "en-GB",
 "leftPronunciationId": "pron.en.gb.ship.1",
 "rightPronunciationId": "pron.en.gb.sheep.1",
 "contrastId": "contrast.en.gb.ɪ-iː",
 "objectiveIds": ["discriminate.en.gb.ɪ-iː"],
 "status": "candidate"
}
```

6. Multilingual by design

Разделить targetLanguage (изучаемый язык), contentLocale (язык пояснений/переводов) и uiLocale (язык интерфейса). Три настройки независимы, даже если первая версия поддерживает только английский как изучаемый язык.

- Идентификаторы LearningItem и LearningObjective не должны зависеть от родного языка пользователя.
- Переводы/значения/пояснения должны быть отдельными локализованными данными; один оригинальный Utterance может иметь несколько переводов с контекстными вариантами.
- UI-локализация — отдельный ресурсный пакет; перевод кнопок не означает готовности упражнений на таком языке.
- Новый target language может требовать отдельного лингвистического движка и своих фонологических систем.

7. Хранение, реализация и архитектурные границы

На раннем этапе: статические JSON/JSONL данные, JSON Schema и Git; TypeScript-домен без зависимости от UI; frontend на TS (с React/Vite или без UI-фреймворка), browser storage для прогресса. Backend Spring Boot/PostgreSQL — когда появятся реальные потребности в аккаунтах, синхронизации, рекомендациях и т.д.

Возможная структура репозитория: catalog/{language}/items, utterances, pronunciations, minimal-pairs; taxonomy; locales/ui/{locale}; locales/content/{locale}; schemas; provenance; exercises; validation. Большие корпуса лучше хранить в JSONL, поддерживая стабильные ID и версионирование схем.

- Нужны линтер и тесты: структура слотов, согласование, допустимость преобразования, грамматика, естественность и смысловая эквивалентность перевода.
- Детерминированная проверка пригодна для однозначных форм; альтернативные ответы требуют более гибкой evaluation policy. LLM может помогать редактору, но не является источником гарантированной правильности.
- Разделять каталожную сущность, реальный текст, генерируемую задачу и прогресс пользователя.

8. Контентный pipeline и контроль качества

1. Найти кандидатов в авторитетных источниках и записать provenance/license.
2. Нормализовать, дедуплицировать, классифицировать, назначить смысловые значения и scope.
3. Определить возможные учебные цели и допустимые drillCapabilities.
4. Подобрать или написать 20–50 контекстных примеров для приоритетных паттернов.
5. Проверить естественность английского, смысл переводов, грамматику, уровень и юридический статус.
6. Зарезервировать отдельные контрольные предложения для проверки переноса навыка.
7. Публиковать только прошедший review контент, с версиями и возможностью отката.

9. Метрики и проверка продуктовой гипотезы

Activation: первая завершённая тренировка; D7 retention; число упражнений за сессию; ошибки по objectives; точность/время ответа; learning gain на новых тестовых материалах. Время ответа интерпретировать вместе с точностью, не как самостоятельный показатель владения речью.

Проверка на небольшой группе пользователей до масштабной разработки, прежде чем инвестировать в сложный backend, мобильные клиенты или массовую генерацию контента.

10. Решения и вопросы для следующего этапа

Согласованные решения

- Отдельные вкладки Table Drills, Translation Drills и Pattern Drills.
- Каталог без искусственного числового потолка; сохранять классификацию, источники и статусы.
- Мультиязычность как базовый инвариант модели; UI и учебные объяснения локализуются независимо.
- LearningObjective — центральный объект процесса обучения; LearningItem — контентная идентичность, Utterance — пример.
- Новая фонологическая подсистема для минимальных пар, не перегружающая Lexeme.

Открытые вопросы / не фиксировать преждевременно

- Юридически допустимый способ использования полного Oxford Phrase List и точная версия (650/750).
- Фактические CEFR и частотность каждого LearningItem (не подменять экспертной оценкой).
- Полный каталог, схема sense-level identity, критерии объединения/разделения записей.
- Система оценивания pronunciation production и достаточное качество аудиокорпуса.

- В какой момент вводить сервер и учетные записи.

Первый backlog при возвращении к проекту

8. Заморозить контракт domain IDs и JSON Schema v0.1.
9. Создать рабочий репозиторий каталога с таксономией и лицензиями.
10. Рефакторить старый генератор, устранить ошибочные русско-английские эквиваленты.
11. Подготовить пилот 15–20 Pattern Drills с ручной лингвистической проверкой.
12. Добавить 10–20 минимальных пар как проверку расширяемости модели.
13. Провести пользовательское тестирование и зафиксировать метрики обучения.

11. Справочные источники для будущей проверки

- Oxford Phrase List — https://www.oxfordlearnersdictionaries.com/wordlists/
- English Vocabulary Profile — https://www.englishprofile.org/
- Cambridge English Grammar Today — https://dictionary.cambridge.org/grammar/british-grammar/
- British Council LearnEnglish Grammar — https://learnenglish.britishcouncil.org/free-resources/grammar
- Tatoeba (условия лицензирования проверять для каждого используемого набора) — https://tatoeba.org/en/downloads

Примечание: ссылки — ориентиры для будущего исследования; этот документ фиксирует обсуждение и архитектурные рекомендации, не утверждает, что списки источников свободны для массового копирования.